

# Análisis de Series de Tiempo

## Carrera de Especialización en Inteligencia Artificial

---

Clase 2

Ing. Magdalena Bouza, Ing. Carlos German Carreño Romano

# Agenda

---


1. Revisión de actividad
2. Herramientas de preprocesamiento: transformación, diferenciación, promedio
3. Tendencia determinística
4. Explicación del Trabajo Práctico.
5. Modelos lineales, de promedio móvil y autorregresivos (AR, MA, ARMA)

# Revisión actividad

# Ejemplos actividad Clase 1

## Ejercicio 1



Graficar una serie a partir de un dataset relevante. Explicar observaciones



Bolsa y Mercado Argentino – Precio Cierre  
23/05/2017 – 29/06/2021

*La evolución del último precio presenta cierta estabilidad hasta mediados del año 2020, entorno a un valor de 300. Luego, quizás por efecto de la pandemia, podemos ver un incremento del precio en forma constante, hasta llegar a mediados del 2021, donde toca su valor máximo histórico (en el tiempo analizado).*

### 1 - Análisis visual





- La serie tiene un offset y parece tener una tendencia anual a incrementar las ventas.
- No parece estacionaria, y podría tener alguna estacionalidad del tipo semestral (vender más en una temporada que otra).

Facultad de Ingeniería Universidad de Buenos Aires

7

### 1 - Analizar la distribución



- La distribución tiene skew positiva, lo cual confirma que los valores incrementan con el tiempo.
- Dicho lo anterior, la serie no es estacionaria (varianza variable).

Facultad de Ingeniería Universidad de Buenos Aires

8

# Preprocesamiento

# Análisis de Series de Tiempo

---

Box and Jenkins plantean tres etapas de **modelado**:

## 1. Especificaciones

- a. Gráficos
- b. Estadísticas
- c. Contexto


## 2. Ajuste

- a. Parámetros
- b. Valores

## 3. Diagnóstico

- a. Testing

*“everything should be made as simple as possible but no simpler”*



## ¿ Cuándo aplicar un preprocesamiento?

---

Cuando la distribución de la serie de tiempo cambia a lo largo del tiempo se dice que es **no estacionaria**.

En estos casos, pueden aplicarse transformaciones para que la serie de tiempo resultante sea aproximadamente estacionaria.

Algunos métodos:

1. Transformación de variables
2. Diferenciación
3. Promedio móvil

# 1. Transformación de variables

---





Muchas series de tiempo tienen la característica de que sus varianzas van aumentando a medida que avanza el tiempo.

Se pueden aplicar transformaciones a los puntos de la serie de tiempo.

- Transformación Box-Cox

$$y_i^{(\lambda)} = \begin{cases} \frac{y_i^\lambda - 1}{\lambda} & \text{si } \lambda \neq 0, \\ \ln y_i & \text{si } \lambda = 0 \end{cases}$$

# 1. Ejemplos



## 2. Diferenciación

---

Si la serie presenta un tendencia se puede analizar en su lugar la serie diferenciada. Dada una serie de tiempo  $y_n$ ,  $n = 0, 1, \dots$  definimos

$$z_n = \Delta y_n = y_n - y_{n-1}$$

**Motivación:** si  $y_n = an + b$ , al diferenciar se obtiene una constante.

**Observación:** En general, si  $y_n$  se corresponde con un polinomio de grado  $n$ , diferenciando  $n$  veces se recupera una constante.

# Ejemplos

---




Figure 1.2: *Difference of the logarithm of the Nikkei 225 data.*

### 3. Promedio móvil

Para una serie de tiempo  $y_n$ , el promedio móvil de  $(2k + 1)$  términos está dado por

$$T_n = \frac{1}{2k+1} \sum_{j=-k}^k y_{n+j}$$

Si modificamos la definición intercambiando la media por la mediana obtenemos la mediana móvil, definida como

$$T_n = \text{mediana}\{y_{-k}, \dots, y_k\}$$

En general, la mediana móvil puede capturar cambios en la tendencia más rápido que el promedio móvil.




Figure 1.4 Maximum temperature data and its moving average. Top left: original data, top right: moving average with  $k = 5$ , bottom left:  $k = 17$ , bottom right:  $k = 29$ .

# Transformación logarítmica

---

¿Cuándo usar la transformación logarítmica?

- Cuando observamos que la varianza del proceso parece aumentar con el tiempo.  
En particular si  $\mathbb{E}[Y_t] = \mu_t$  y  $\sqrt{\text{var}(Y_t)} = \mu_t\sigma$ , luego  $\mathbb{E}[\log(Y_t)] \approx \log(\mu_t)$  y  $\text{var}(\log(Y_t)) \approx \sigma^2$
- Si  $Y_t$  tiene cambios porcentuales relativamente estables entre un instante de tiempo y otro, y supongamos que  $Y_t = (1 + X_t)Y_{t-1}$ . Luego tomando el log

$$\log(Y_t) = \log((1 + X_t)Y_{t-1}) = \log(1 + X_t) + \log(Y_{t-1}) \rightarrow \log(Y_t) - \log(Y_{t-1}) = \log\left(\frac{Y_t}{Y_{t-1}}\right) = \log(1 + X_t)$$

Si además suponemos que  $X_t$  está acotado,  $|X_t| < 0.2$ , sucede que



$\log(1 + X_t) \approx X_t$  y  $\nabla(\log Y_t) \approx X_t$  va a ser relativamente estable y posiblemente se encuentre bien modelada por un poc. estacionario.

# Análisis de tendencia

# Tendencia estocástica vs. tendencia determinística

---

Si bien no hay una definición unificada de qué son las **tendencias estocásticas**, se puede decir que son aquellas que un observador podría hallar al analizar una realización de una serie de tiempo, pero que si se tiene una realización distinta esa tendencia cambia.



## Tendencia estocástica vs. tendencia determinística

---

La **tendencia determinística** es aquella que viene dada por el modelo, y es fija para toda la serie de tiempo, sin importar que realización se tenga. *Por ejemplo las variaciones cíclicas a lo largo de las distintas estaciones del año.*

En el caso de la tendencia determinística, podemos estimarla y descontarla de la serie de tiempo. Esta situación se puede modelar como

$$Y_t = X_t + \mu_t$$

donde  $\mu_t$  es la tendencia determinística y  $X_t$  es una serie de tiempo de media cero alrededor de  $\mu_t$ .

# Algunos modelos comunes para tendencia

---

- Constante:  $\mu_t = \mu \quad \forall t$
- Lineal:  $\mu_t = \beta_0 + \beta_1 t \quad \forall t$
- Cuadrática:  $\mu_t = \beta_0 + \beta_1 t + \beta_2 t^2 \quad \forall t$
- Cíclicas:  $\mu_t = \mu_{t-T} \quad \forall t$ , donde T es el período del ciclo. *Ejemplo: temperatura a lo largo del año tiene un período de T=12 meses*
- Coseno:  $\mu_t = \beta \cos(2\pi ft + \phi) \quad \forall t$

## ¿Cómo estimar estas tendencias?

---

Suele emplearse el método de cuadrados mínimos para estimar los valores de los parámetros que describen la tendencia.

Si llamamos  $f(t; \theta)$  a los modelos presentados anteriormente, buscamos hallar los parámetros  $\theta$  que minimicen el ECM. Es decir, buscamos  $\theta$  que minimice

$$Q(\theta) = \frac{1}{n} \sum_{i=1}^n (y_t - f(t; \theta))^2$$

## Caso constante:

---

$$\begin{bmatrix} y_n \\ y_{n-1} \\ \vdots \\ y_1 \end{bmatrix} = \begin{bmatrix} 1 \\ 1 \\ \vdots \\ 1 \end{bmatrix} \mu + \begin{bmatrix} x_n \\ x_{n-1} \\ \vdots \\ x_1 \end{bmatrix}$$

Luego, la solución por c.m. es

$$\mu = \underbrace{\left( \begin{bmatrix} 1 & \cdots & 1 \end{bmatrix} \begin{bmatrix} 1 \\ \vdots \\ 1 \end{bmatrix} \right)^{-1}}_n \begin{bmatrix} 1 & \cdots & 1 \end{bmatrix} \begin{bmatrix} y_n \\ y_{n-1} \\ \vdots \\ y_1 \end{bmatrix} = \frac{1}{n} \sum_{t=1}^n y_t$$

## Caso lineal

---

$$\begin{bmatrix} y_n \\ y_{n-1} \\ \vdots \\ y_1 \end{bmatrix} = \begin{bmatrix} 1 & n \\ 1 & n-1 \\ \vdots & \vdots \\ 1 & 1 \end{bmatrix} \begin{bmatrix} \beta_0 \\ \beta_1 \end{bmatrix} + \begin{bmatrix} x_n \\ x_{n-1} \\ \vdots \\ x_1 \end{bmatrix}$$


Y la solución por c.m resulta

$$\begin{bmatrix} \hat{\beta}_0 \\ \hat{\beta}_1 \end{bmatrix} = \left( \begin{bmatrix} 1 & n \\ 1 & n-1 \\ \vdots & \vdots \\ 1 & 1 \end{bmatrix}^T \begin{bmatrix} 1 & n \\ 1 & n-1 \\ \vdots & \vdots \\ 1 & 1 \end{bmatrix} \right)^{-1} \begin{bmatrix} 1 & n \\ 1 & n-1 \\ \vdots & \vdots \\ 1 & 1 \end{bmatrix}^T \begin{bmatrix} y_n \\ y_{n-1} \\ \vdots \\ y_1 \end{bmatrix} =$$

$$\hat{\beta}_1 = \frac{\sum_{t=1}^n (y_t - \bar{y})(t - \frac{n+1}{2})}{\sum_{t=1}^n (t - \frac{n+1}{2})^2} \quad \hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \frac{n+1}{2}$$

# Caso lineal

```
from scipy.optimize import curve_fit
# define the true objective function
def objective(x, a, b):
    return a * x + b
```



```
dataframe = read_csv(url, header=None)
data = dataframe.values
# choose the input and output variables
x, y = data[:, 4], data[:, -1]
# curve fit
popt, _ = curve_fit(objective, x, y)
# summarize the parameter values
a, b = popt
print('y = %.5f * x + %.5f' % (a, b))
# plot input vs output
pyplot.scatter(x, y)
# define a sequence of inputs between the smallest and largest observed
x_line = arange(min(x), max(x), 1)
# calculate the output for the range
y_line = objective(x_line, a, b)
# create a line plot for the mapping function
pyplot.plot(x_line, y_line, '--', color='red')
pyplot.show()
```

## Caso cuadrático

---

$$\begin{bmatrix} y_n \\ y_{n-1} \\ \vdots \\ y_1 \end{bmatrix} = \underbrace{\begin{bmatrix} 1 & n & n^2 \\ 1 & n-1 & (n-1)^2 \\ \vdots & \vdots & \\ 1 & 1 & 1 \end{bmatrix}}_A \begin{bmatrix} \beta_0 \\ \beta_1 \\ \beta_2 \end{bmatrix} + \begin{bmatrix} x_n \\ x_{n-1} \\ \vdots \\ x_1 \end{bmatrix}$$

Y la solución por c.m. queda


$$\begin{bmatrix} \hat{\beta}_0 \\ \hat{\beta}_1 \\ \hat{\beta}_2 \end{bmatrix} = (A^T A)^{-1} A^T \begin{bmatrix} y_n \\ y_{n-1} \\ \vdots \\ y_1 \end{bmatrix}$$

# Caso cuadrático

---

```
# define the true objective function
def objective(x, a, b, c):
    return a * x + b * x**2 + c

# choose the input and output variables
x, y = data[:, 4], data[:, -1]
# curve fit
popt, _ = curve_fit(objective, x, y)
# summarize the parameter values
a, b, c = popt
print('y = %.5f * x + %.5f * x^2 + %.5f' % (a, b, c))
# plot input vs output
pyplot.scatter(x, y)
# define a sequence of inputs between the smallest and
# largest observed values
x_line = arange(min(x), max(x), 1)
# calculate the output for the range
y_line = objective(x_line, a, b, c)
```



## Caso cíclico


---

$$\mu_t = \begin{cases} \beta_1 & t = 1, 1+T, 1+2T, \dots \\ \beta_2 & t = 2, 2+T, 2+2T, \dots \\ \vdots & \\ \beta_T & t = T, 2T, 3T, \dots \end{cases}$$

$$\begin{bmatrix} y_n \\ y_{n-1} \\ \vdots \\ y_1 \end{bmatrix} = A \begin{bmatrix} \beta_1 \\ \beta_2 \\ \vdots \\ \beta_T \end{bmatrix} + \begin{bmatrix} x_n \\ x_{n-1} \\ \vdots \\ x_1 \end{bmatrix}, \quad a_{i,j} = \begin{cases} 1 & (i \bmod j) = 0 \\ 0 & (i \bmod j) \neq 0 \end{cases}$$


# Análisis de series de tiempo

---



Cada período presenta picos y valles bien marcados. La serie cae en sus valles a valores mínimos que suelen mantener un valor absoluto regular. En cada período se pueden observar dos picos a una distancia regular, donde el valor del segundo pico supera siempre al primero. Ambos picos tienen variaciones en su valor absoluto, a diferencia de los valles.

# Ajuste por cuadrados mínimos: caso cíclico



ver ejemplo: [linearRegression24hs.py](#)

```
dataset=sig
interval=1
diff = list()
for i in range(interval, len(dataset)):


    value = dataset[i] - dataset[i - interval]
    diff.append(value)

plt.plot(sig)
plt.plot(diff)
plt.legend(['sig','diff'])
plt.show()

#repito la estimacion pero para la diferenciada
N=24 #hours
dataframe = pd.Series(pd.concat([pd.Series(diff[0]),p
ts=pd.DataFrame(dataframe.values)
rows=int(len(ts)/N)
data = ts.values.reshape(rows,N)

betas=data.mean(axis=0)
```

## Ajuste por cuadrados mínimos: caso cíclico



Usando la técnica de cuadrados mínimos se pueden estimar los valores promedio de los períodos.

Luego si se resta a la serie original la serie estimada por cuadrados mínimos se obtiene una serie que puede servir para analizar estacionariedad.

## Caso coseno

---

Reescribiendo la tendencia podemos llevarla a una expresión lineal:

$$\mu_t = \beta \cos(2\pi ft + \phi) = \beta_1 \cos(2\pi ft) + \beta_2 \cos(2\pi ft),$$

$$\beta_1 = \beta \cos(\phi), \beta_2 = \beta \sin(\phi)$$

$$\begin{bmatrix} y_n \\ y_{n-1} \\ \vdots \\ y_1 \end{bmatrix} = \underbrace{\begin{bmatrix} 1 & \cos(2\pi fn) & \sin(2\pi fn) \\ 1 & \cos(2\pi f(n-1)) & \sin(2\pi f(n-1)) \\ \vdots & \vdots & \vdots \\ 1 & \cos(2\pi f1) & \sin(2\pi f1) \end{bmatrix}}_A \begin{bmatrix} \beta_0 \\ \beta_1 \\ \beta_2 \end{bmatrix} + \begin{bmatrix} x_n \\ x_{n-1} \\ \vdots \\ x_1 \end{bmatrix}$$

## ¡Cuidado!

---

Los resultados por cuadrados mínimos son válidos estrictamente sólo cuando  $X_t$  es un proceso blanco (las muestras temporales son independientes entre sí).

Sin embargo, se puede demostrar que si el proceso es estacionario los resultados son asintóticamente válidos, y sus varianzas coinciden con la de los estimadores de mínima varianza para los parámetros.

## Estimando Xt

---

Los valores de Xt pueden ser estimados a partir de los residuos de la estimación de los parámetros:

$$\hat{x}_t = y_t - \hat{\mu}_t$$

# Trabajo práctico

# Trabajo Práctico

---

- Graficar una serie a partir de un dataset relevante. **Describir** observaciones.
- **Descomponer** una serie de tiempo usando el modelo aditivo de cuatro componentes.
- Extraer la **tendencia** y ajustar un **modelo determinístico**. Explicar su relación con el contexto. Obtener conclusiones acerca de la validez del modelo.
- **Entrega clase 4:** Evaluar si la serie original es **estacionaria**. Aplicar transformaciones (**preprocesamiento**), graficar autocorrelación, autocorrelación parcial y extraer conclusiones.

# Trabajo Práctico

---

- **Entrega clase 6:** A partir de las transformaciones propuestas ajustar distintos **modelos (S)ARIMA**. Extraer orden, parámetros, coeficientes numéricos y análisis de la bondad del modelo.
- Ajustar y predecir usando **redes neuronales LSTM**. Comparar con **predicciones** usando SARIMA y extraer conclusiones.
- Reailzar el **análisis espectral** de la serie original. Hallar las frecuencias principales y comparar con las **componentes cíclica y estacional** usando la descomposición.
- **Entrega clase 8:** Presentación incluyendo introducción, gráficos, modelos propuestos, expresiones analíticas y conclusiones.

# Modelos para series de tiempo estacionarias

## Proceso lineal general

---

Sean  $\{Y_t\}$  la serie de tiempo observada y  $\{e_t\}$  una serie de ruido blanco no observable.  $\{e_t\}$  es una secuencia de v.a. i.i.d, con media cero y varianza  $\sigma_e^2$ .

Un proceso lineal general es aquel que puede representarse como una combinación lineal de términos presentes y pasados del proceso de ruido blanco:

$$Y_t = e_t + a_1 e_{t-1} + a_2 e_{t-2} + \dots$$

Si la cantidad de términos a sumar es infinita se pide que  $\sum_{i=1}^{\infty} a_i^2 < \infty$ .

Se puede demostrar que:

- $\mathbb{E}[Y_t] = 0$
- $C_k = \text{cov}(Y_t, Y_{t-k}) = \sigma_e^2 \sum_{i=1}^{\infty} a_i a_{i+k}, \quad k \geq 0$

# Modelo de promedios móviles

Un **modelo de promedio móvil (MA)** es un modelo lineal general donde existe una cantidad finita términos  $a_i \neq 0$ .

Diremos que  $\{Y_t\}$  es un modelo de promedio móvil de orden  $q$  (MA( $q$ )) si

$$Y_t = e_t - a_1 e_{t-1} - \dots - a_q e_{t-q}$$

Los parámetros de este modelo son los pesos  $a_1, \dots, a_q$ .

Para estos modelos,

$$C_0 = (1 + a_1^2 + \dots + a_q^2) \sigma_e^2$$


~~$\frac{C_0}{C_0}$~~

$$R_k = \begin{cases} \frac{-a_k + a_1 a_{k+1} + a_2 a_{k+2} + \dots + a_{1-k} a_q}{1 + a_1^2 + \dots + a_q^2} \frac{\sigma_e^2}{\sigma_e^2} & k = 1, 2, \dots, q \\ 0 & k > q \end{cases}$$


# Ejemplo!

---

```
ma_ts = arma_generate_sample(  
    ar=[1], ma=np.r_[1,ma_coef], nsample =100)
```



```
plot_acf(ma_ts, ax= ax)  
plt.plot(arma_acf(ar=[1],  
    ma=np.r_[1,ma_coef], lags=20))
```



# Modelo autoregresivo

---

Los modelos autorregresivos incluyen regresiones sobre sí mismos.

Diremos que  $Y_t$  es un modelo autorregresivo de orden  $p$  (AR( $p$ )) si cumple que

$$Y_t = a_1 Y_{t-1} + \dots + a_p Y_{t-p} + e_t \rightarrow \text{innovación}$$

Suponemos entonces que para cada  $t$ ,  $e_t$  es independiente de  $Y_{t-1}, Y_{t-2}, \dots$

El modelo AR( $p$ ) tiene asociado su polinomio característico definido como:

$$\phi(x) = 1 - a_1 x + a_2 x^2 + \dots + a_p x^p$$

Se puede demostrar que el proceso es AR( $q$ ) es estacionario si las raíces  $\phi(x)$  se encuentran fuera del círculo unitario (módulo mayor a 1)


# Modelo AR(1)

---

Si  $p=1$ , tenemos que  $Y_t = a_1 Y_{t-1} + e_t$ , luego  $\mathbb{E}[Y_t] = 0$ .

Puedo tomar la varianza miembro a miembro para obtener

$$\text{var}(Y_t) = a_1^2 \text{var}(Y_{t-1}) + \sigma_e^2 \rightarrow C_0 = a_1^2 C_0 + \sigma_e^2 \Rightarrow C_0 = \frac{\sigma_e^2}{1-a_1^2}$$



Además,





$$\begin{aligned} C_k &= \text{cov}(Y_{t-k}, Y_t) = \text{cov}(Y_{t-k}, a_1 Y_{t-1} + e_t) \\ &= a_1 \underbrace{\text{cov}(Y_{t-k}, Y_{t-1})}_{C_{k-1}} + \underbrace{\text{cov}(Y_{t-k}, e_t)}_0 \\ &= a_1 C_{k-1} \end{aligned}$$

A partir del valor semilla de  $C_0$  obtenemos de forma recursiva que

$$C_k = a_1^k \frac{\sigma_e^2}{1-a_1^2}$$

# Modelo AR(1)

---



## Modelo AR(1) como un proceso lineal general

---

Para comprender el modelo, la expresión dada para el modelo AR(1) es muy útil, sin embargo para muchas otras cosas es necesario llevarlo a la forma de un proceso general lineal.

Para eso comenzamos reemplazando  $Y_{t-1}$  por  $a_1 Y_{t-2} + e_{t-1}$ :

$$Y_t = a_1(a_1 Y_{t-2} + e_{t-1}) + e_t = a_1^2 Y_{t-2} + a_1 e_{t-1} + e_t$$

aplicando la misma idea (k-1) veces:

$$Y_t = a_1^k e_{t-k} + a_1^{k-1} e_{t-k+1} + \dots + a_1 e_{t-1} + e_t$$

Asumiendo  $|a_1| < \infty$  e incrementando k sin límite tenemos que

$$Y_t = e_t + a_1 e_{t-1} + a_1^2 e_{t-2} + a_1^3 e_{t-3} + \dots$$

$$Y_t = e_t + \psi_1 e_{t-1} + \psi_2 e_{t-2} + \psi_3 e_{t-3} + \dots$$

## Modelo AR(p)

---

Se puede mostrar que una condición necesaria (pero no suficiente) para que el proceso sea estacionario es que  $a_1 + a_2 + \dots + a_p < 1$  y  $|a_p| < 1$ .

Al igual que como hicimos para el AR(1), podemos calcular la función de autocovarianza y autocorrelación:

$$\begin{aligned} C_k &= cov(Y_t, Y_{t-k}) = cov(a_1 Y_{t-1}, Y_{t-k}) + \dots + cov(a_p Y_{t-p}, Y_{t-k}) + cov(e_t, Y_{t-k}) \\ &= a_1 C_{k-1} + \dots + a_p C_{k-p} \end{aligned}$$

$$R_k = \frac{cov(Y_t, Y_{t-k})}{C_0} = a_1 R_{k-1} + \dots + a_p R_{k-p}$$

## Modelo AR(p)

---

Evaluando para  $k=1, \dots, p$  y recordando que  $R_0 = 1$  y  $R_k = R_{-k}$  obtenemos las **ecuaciones de Yule-Walker (Y-W)**:

$$\begin{cases} R_1 = a_1 + a_2 R_1 + \dots + a_p R_{p-1} \\ \vdots \\ R_p = a_1 R_{p-1} + a_2 R_{p-2} + \dots + a_p R_p \end{cases}$$

Dado los valores de  $a_1, \dots, a_p$ , se puede resolver el sistema de ecuaciones para hallar  $R_1, \dots, R_p$


Finalmente, podemos usar estos valores para hallar  $C_0 = a_1 C_1 + \dots + a_p C_p + \sigma_e^2$  observando que

$$C_0 = a_1 R_1 C_0 + \dots + a_p R_p C_0 + \sigma_e^2 \Rightarrow C_0 = \frac{\sigma_e^2}{1 - a_1 R_1 - \dots - a_p R_p}$$


# Ejemplo!

---

```
ar_coef  = np.array([0.8,-0.2])
ar_ts = arma_generate_sample(ar=np.r_[1,-ar_coef],
                            ma=[1], nsample =100)
```



```
plot_acf(ar_ts, ax=ax)
plt.plot(arma_acf(ar=np.r_[1,-ar_coef],
                  ma=[1], lags=20))
```



# Modelo ARMA

---

El modelo arma es una combinación de un proceso AR con un MA. Diremos que  $\{Y_t\}$  sigue un modelo ARMA(p,q) si

$$Y_t = a_1 Y_{t-1} + \dots + a_p Y_{t-p} + e_t - b_1 e_{t-1} - \dots - b_q e_{t-q}$$

Si se satisfacen las condiciones de estacionariedad, el modelo ARMA(p,q) puede reescribirse como un proceso lineal general con coeficientes  $\psi_1, \psi_2, \dots$  dados por:

$$\begin{cases} \psi_0 = 1 \\ \psi_1 = -b_1 + a_1 \\ \psi_2 = -b_2 + a_2 + a_1 \psi_1 \\ \vdots \\ \psi_j = -b_j + a_p \psi_{j-p} + a_{p-1} \psi_{j-p+1} + \dots + a_1 \psi_{j-1} \end{cases} \quad \psi_j = 0, \text{ si } j < 0 \text{ y } b_j = 0 \text{ si } j > q$$

## ARMA(p,q)

---

Se puede ver que la función de autocorrelación está dada por:

$$\begin{cases} C_0 = a_1 C_1 + a_2 C_2 + \dots - \sigma_e^2 (b_0 + b_1 \psi_1 + \dots + b_q \psi_q) \\ C_1 = a_1 C_0 + a_2 C_1 + \dots + a_p C_{p-1} - \sigma_e^2 (b_1 + b_2 \psi_1 + \dots + b_1 \psi_{q-1}) \\ \vdots \\ C_p = a_1 C_{p-1} + a_2 C_{p-2} + \dots + a_p C_0 - \sigma_e^2 (b_p + b_{p+1} \psi_1 + \dots + b_q \psi_{q-p}) \end{cases}$$


Si  $k > q$  entonces la expresión puede simplificarse como:

$$C_k = a_1 C_{k-1} + a_2 C_{k-2} + \dots + a_p C_{k-p}$$


# Ejemplo!

---

```
arma_ts = arma_generate_sample(  
    ar=np.r_[1,-ar_coef], ma=np.r_[1,ma_coef],  
    nsample =100)
```



```
plot_acf(arma_ts, ax=ax)  
plt.plot(arma_acf(ar=np.r_[1, -ar_coef],  
    ma=np.r_[1,ma_coef], lags=20))
```



# Conclusiones

---

- Hemos visto un camino para modelar series de tiempo basado en **tres partes: identificación, ajuste y test**.
- Usamos **transformaciones**, extraemos información y **proponemos un modelo**, estocástico o determinista
- Vimos modelos con **tendencia determinística** con ejemplos: **lineal, cuadrático, cílico y coseño**
- Hicimos ajustes por **cuadrados mínimos** para encontrar los **valores de los parámetros** a estimar
- En la segunda parte, vimos **modelos estocásticos: MA, AR y ARMA**
- Estudiamos las propiedades a partir de la **Autocorrelación y Autocovarianza**
- **Generalizamos** los resultados **de forma analítica**
- Buscamos **identificar los parámetros** y sus valores para modelos estocásticos
- Nos vamos a concentrar la próxima clase en probar y medir la **bondad del modelo** propuesto